Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра «Автоматизированные системы обработки информации и управления»



Отчет по Лабораторной Работе № 4

«Подготовка обучающей и тестовой выборки, кроссвалидация и подбор гиперпараметров на примере метода ближайших соседей»

По курсу

«Методы машинного обучения»

Выполнила: Шаххуд Ф.М. Студентка группы ИУ5И-22М

Цель лабораторной работы

Изучение сложных способов подготовки выборки и подбора гиперпараметров на примере соседей.

```
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from scipy import stats
from sklearn.datasets import *
from sklearn.model selection import train test split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.model selection import cross val score, cross validate
from sklearn.model selection import KFold, RepeatedKFold, LeaveOneOut, LeavePOut, S
from sklearn.metrics import accuracy score, balanced accuracy score
from sklearn.metrics import plot confusion matrix
from sklearn.metrics import precision score, recall score, f1 score,
from sklearn.metrics import confusion matrix
from sklearn.metrics import mean absolute error , mean squared error , mean sc
from sklearn.metrics import roc_curve, roc_auc_score
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.model_selection import learning_curve, validation_curve
import seaborn as sns
import matplotlib.pyplot as
% matplotlib inline
sns . set ( style = "ticks" )
```

/usr/local/lib/python3.6/dist-packages/statsmodels/tools/_testing.py:19: Futur import pandas.util.testing as tm

Набор данных

Наш набор данных взят с сайта Kaggle. Он описывает спецификацию подержанного автом предсказать цену автомобиля. Поэтому наша задача - построить модель машинного обуче регрессора для цены автомобилей.

```
data = pd.read_csv('car data.csv')
data.head()
```

 \Box

```
Car_Name Year Selling_Price Present_Price Kms_Driven Fuel_Type Seller_

O ritz 2014 3.35 5.59 27000 Petrol Cata.shape

Car_Name Year Selling_Price Present_Price Kms_Driven Fuel_Type Seller_Type Sell
```

Подготовка данных и построение базовых моделей для качества

▼ Обработка пропусков в числовых данных

dtype='object')

Проверка, содержит ли наш набор данных недостающие данные.

```
data.isnull().sum()
Car_Name
                      0
                      0
    Year
    Selling_Price
                      0
    Present Price
    Kms Driven
    Fuel Type
    Seller_Type
                      0
    Transmission
                      0
                      0
    Owner
    dtype: int64
```

Наш набор данных не содержит недостающих данных.

Мы проверим, есть ли переменные объекта, чтобы преобразовать их в числовые значения

```
data.dtypes
```

[→

▼ Кодирование категориальных признаков

У нас будет простой кодировщик для кодирования значений типа объекта.

```
Trancmiccion
                      ohiect
np.unique(data.Fuel_Type)
ray(['CNG', 'Diesel', 'Petrol'], dtype=object)
from sklearn.preprocessing import LabelEncoder
LE=LabelEncoder()
data_Fuel=LE.fit_transform(data['Fuel_Type'])
data['Fuel_Type']=data_Fuel
np.unique(data.Seller_Type)
□ array(['Dealer', 'Individual'], dtype=object)
data_Seller=LE.fit_transform(data.Seller_Type)
data.Seller_Type=data_Seller
np.unique(data.Transmission)
array(['Automatic', 'Manual'], dtype=object)
data_Tran=LE.fit_transform(data.Transmission)
data.Transmission=data Tran
np.unique(data.Car_Name)
```

₽		Car_Name	Year	Selling_Price	Present_Price	Kms_Driven	Fuel_Type	Selle
	0	ritz	2014	3.35	5.59	27000	2	
	1	sx4	2013	4.75	9.54	43000	1	
	2	ciaz	2017	7.25	9.85	6900	2	
	3	wagon r	2011	2.85	4.15	5200	2	
	4	swift	2014	4.60	6.87	42450	1	
	273	jazz	2010	2.25	7.50	61203	2	
	274	brio	2014	5.30	6.80	16500	2	
	278	jazz	2016	6.00	8.40	4000	2	
	285	jazz	2016	7.40	8.50	15059	2	
	287	amaze	2015	5.75	7.50	44000	2	

225 rows × 9 columns

```
data.Car Name.value counts()
                                 26
City
    corolla altis
                                 16
    verna
                                 14
    fortuner
                                 11
    brio
                                 10
    Yamaha FZ 16
                                  1
    Bajaj Discover 100
                                  1
    Honda CB Unicorn
                                  1
    Royal Enfield Bullet 350
                                 1
    Name: Car Name, Length: 98, dtype: int64
```

Поскольку названия автомобилей не являются уникальными, мы можем использовать инспохожих имен автомобилей. Итак, мы собираемся закодировать все названия автомобиле

```
data_Name=LE.fit_transform(data.Car_Name)
```

data.car_name-data_name

data.dtypes

₽	Car_Name	int64
_	Year	int64
	Selling_Price	float64
	Present_Price	float64
	Kms_Driven	int64
	Fuel_Type	int64
	Seller_Type	int64
	Transmission	int64
	Owner	int64
	dtype: object	

data.head()

С→

₽		Car_Name	Year	Selling_Price	Present_Price	Kms_Driven	Fuel_Type	Seller_
	0	90	2014	3.35	5.59	27000	2	
	1	93	2013	4.75	9.54	43000	1	
	2	68	2017	7.25	9.85	6900	2	
	3	96	2011	2.85	4.15	5200	2	
	4	92	2014	4.60	6.87	42450	1	

▶ Разделение выборки на обучающую и тестовую

```
X_train, X_test, y_train, y_test = train_test_split(
    data[['Car_Name','Year','Present_Price','Kms_Driven','Fuel_Type','Seller_Type','
X_train.shape, y_train.shape

[> ((210, 8), (210,))

X_test.shape, y_test.shape

[> ((91, 8), (91,))

data.describe()
```

	Car_Name	Year	Selling_Price	Present_Price	Kms_Driven	Fuel_T
count	301.000000	301.000000	301.000000	301.000000	301.000000	301.000
mean	62.571429	2013.627907	4.661296	7.628472	36947.205980	1.787
std	25.573535	2.891554	5.082812	8.644115	38886.883882	0.425
min	0.000000	2003.000000	0.100000	0.320000	500.000000	0.000

Построим базовые модели на основе метода ближайши

```
19/0 UZ.000000 Z010.000000 U.000000 9.000000 T0/0/.000000 Z.000
```

Мы выберем два значения для числа соседей и посмотрим их производительность, исполіметрики.

```
reg1 1 = KNeighborsRegressor(n neighbors=2)
reg1 1.fit(X train, y train)
target2 1 = reg1 1.predict(X test)
len(target2 1), target2 1
   Гэ
         1. , 0. , 1. , 0. , 0.5, 0. , 0. , 0. , 1. , 0.5, 0.5, 0.5, 0.5,
         0.5, 0.5, 0.5, 0.5, 0.5, 0., 0.5, 1., 0., 0.5, 1., 0.5, 0.5, 1.]))
# 10 ближайших соседей
req1 2 = KNeighborsRegressor(n_neighbors=10)
reg1 2.fit(X train, y train)
target2 2 = reg1 2.predict(X test)
len(target2 2), target2 2
(91, array([0.4, 0.3, 0.6, 0.5, 0.5, 0.5, 0.1, 0.4, 0.4, 0.4, 0.1, 0.6,
         0.2, 0.2, 0.6, 0.2, 0.2, 0.2, 0.2, 0.2, 0.2, 0.1, 0.5, 0.4, 0.3,
         0.2, 0.6, 0.2, 0.3, 0.3, 0.2, 0.3, 0. , 0.1, 0.1, 0.3, 0.7, 0.4,
         0.3, 0.2, 0.3, 0.6, 0.1, 0.1, 0.2, 0.2, 0.2, 0.1, 0.3, 0.3, 0.5,
         0.4, 0.2, 0.5, 0.1, 0.1, 0.4, 0.2, 0.4, 0.3, 0.7, 0.4, 0.1, 0.5,
         0.5, 0.1, 0.5, 0.1, 0.3, 0.4, 0.1, 0.1, 0.5, 0.6, 0.2, 0.5, 0.5,
```

Метрики качества классификации

▼ Mean Absolute Error

```
mean_absolute_error(y_test, target2_1)
```

0.8, 0.4, 0.5, 0.6, 0.2, 0.6, 0.5, 0.2, 0.5, 0.5, 0.6, 0.5, 0.5]))

▼ Mean Square Error

→ Median Absolute Error

▼ R2 Score

```
r2_score(y_test, target2_1)

□→ 0.15479876160990724

r2_score(y_test, target2_2)

□→ 0.1848503611971105
```

Стратегии кросс-валидации

→ 1) K-fold

```
kf = KFold(n splits=5)
scores = cross validate(KNeighborsRegressor(n neighbors=2),
                        data[['Car Name', 'Year', 'Present Price', 'Kms Driven',
                              'Fuel_Type', 'Seller_Type', 'Transmission', 'Owner']]
                        , data['Seller Type'], scoring=scoring,
                        cv=kf, return train score=True)
scores
   {'fit time': array([0.00299525, 0.00273657, 0.00267625, 0.00188065, 0.00184083
      'score time': array([0.00376844, 0.0022037 , 0.0020256 , 0.0019753 , 0.001989
     'test_NMAE': array([-0.32786885, -0.26666667, -0.633333333, -0.36666667, -0.4
     'test NMSE': array([-0.22131148, -0.16666667, -0.5
                                                           , -0.28333333, -0.34
     'test_NMedAR': array([-0.5, -0., -0.5, -0.5]),
      'test r2': array([-2.61184211, 0.28229665, 0.
                                                             -0.275
     'train NMAE': array([-0.14166667, -0.14937759, -0.11410788, -0.13485477, -0.1
     'train_NMSE': array([-0.07083333, -0.0746888 , -0.05705394, -0.06742739, -0.0
      'train_NMedAR': array([-0., -0., -0., -0., -0.]),
      train_r2': array([0.71014493, 0.6710646 , 0.63057414, 0.7062078 , 0.73895877'
```

→ 2) Repeated K-Fold

```
kf = RepeatedKFold(n splits=5, n repeats=2)
scores = cross validate(KNeighborsRegressor(n neighbors=2),
                       data[['Car_Name','Year','Present_Price','Kms_Driven',
                              'Fuel Type', 'Seller Type', 'Transmission', 'Owner']]
                        , data['Seller Type'], scoring=scoring,
                       cv=kf, return train score=False)
scores, np.mean(scores['test NMAE'])
({'fit_time': array([0.00447702, 0.00267315, 0.00206423, 0.00201416, 0.0020229
             0.00204992, 0.00208592, 0.00204706, 0.00212574, 0.00203228]),
      'score_time': array([0.00317717, 0.00344634, 0.0024271 , 0.00237226, 0.00225
             0.00220561, 0.00222707, 0.00226998, 0.0022068 , 0.00227284]),
       'test_NMAE': array([-0.22131148, -0.29166667, -0.425
                                                             , -0.31666667, -0.3
             -0.32786885, -0.31666667, -0.275
                                                , -0.30833333, -0.29166667]),
       'test_NMSE': array([-0.15163934, -0.20416667, -0.32083333, -0.23333333, -0.2
             -0.26229508, -0.233333333, -0.1875 , -0.2125 , -0.17916667]),
       'test_NMedAR': array([-0. , -0. , -0.5 , -0. , -0. , -0. , -0. , -0.
             -0.51),
       'test_r2': array([ 0.2929198 , 0.08125 , -0.41025641, 0.05723906, -0.232
             -0.07252747, -0.05 , 0.22857143, 0.01797176, 0.08380682])},
     -0.30908469945355194)
```

→ 3) ShuffleSplit

```
'Fuel_Type', 'Seller_Type', 'Transmission', 'Owner']]

, data['Seller_Type'], scoring=scoring,

cv=kf, return_train_score=False)

scores

From Type', 'Transmission', 'Owner']]

/*County for the county for the county
```

```
{'fit_time': array([0.00326657, 0.00246572, 0.00267696, 0.00183225, 0.00178576
    'score_time': array([0.00692558, 0.00252438, 0.00231409, 0.00207949, 0.002016
    'test_NMAE': array([-0.29605263, -0.31578947, -0.33552632, -0.33552632, -0.33
    'test_NMSE': array([-0.21381579, -0.21052632, -0.25986842, -0.27960526, -0.25
    'test_NMedAR': array([-0. , -0.5 , -0. , -0. , -0.25]),
    'test_r2': array([ 0.10507246,  0.00246103, -0.06605114, -0.54693487, -0.1474
```

Оптимизация гиперпараметров

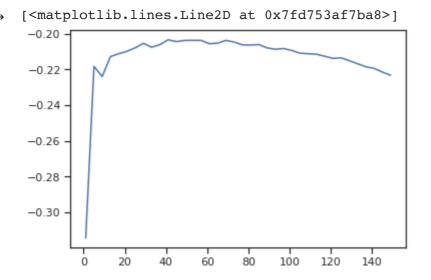
→ Grid Search

regr gs.best params

[→ {'n_neighbors': 41}

```
n_range = np.array(range(1,150,4))
tuned parameters = [{'n neighbors': n range}]
tuned parameters
[ { 'n_neighbors': array([ 1, 5, 9, 13, 17, 21, 25, 29,
                                                                   33, 37,
              53, 57, 61, 65, 69, 73, 77, 81, 85, 89, 93, 97, 101,
             105, 109, 113, 117, 121, 125, 129, 133, 137, 141, 145, 149])}]
r_gs = GridSearchCV(KNeighborsRegressor(), tuned_parameters, cv=5, scoring='neg_mea
r_gs.fit(X_train, y_train)
 GridSearchCV(cv=5, error_score=nan,
                 estimator=KNeighborsRegressor(algorithm='auto', leaf size=30,
                                              metric='minkowski',
                                              metric params=None, n jobs=None,
                                              n neighbors=5, p=2,
                                              weights='uniform'),
                 iid='deprecated', n_jobs=None,
                 param_grid=[{'n_neighbors': array([ 1, 5, 9, 13, 17, 21,
                57, 61, 65, 69, 73, 77, 81, 85, 89, 93, 97, 101,
           105, 109, 113, 117, 121, 125, 129, 133, 137, 141, 145, 149])}],
                 pre dispatch='2*n jobs', refit=True, return train score=False,
                 scoring='neg_mean_squared_error', verbose=0)
regr_gs.best_estimator_
F. KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
                        metric params=None, n_jobs=None, n_neighbors=41, p=2,
                        weights='uniform')
```

```
plt.plot(n_range, regr_gs.cv_results_['mean_test_score'])
```



Обучение модели ближайших соседей для оптимальног

```
regr_gs.best_estimator_.fit(X_train, y_train)
Y_pred = regr_gs.best_estimator_.predict(X_test)

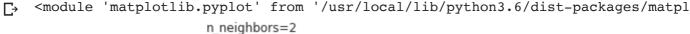
mae = mean_absolute_error(y_test, Y_pred)
mse = mean_squared_error(y_test, Y_pred)
r2 = r2_score(y_test, Y_pred)

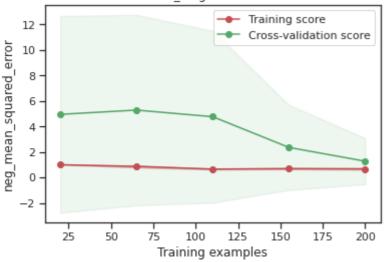
print(regr_models_grid)
print('MAE={}, MSE={}, R2={}'.format(
    round(mae, 3), round(mse, 3), round(r2, 3)))

[> {'KNN_41': KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkows metric_params=None, n_jobs=None, n_neighbors=41, p=2, weights='uniform')}
MAE=0.388, MSE=0.191, R2=0.183
```

- Построение кривых обучения и валидации

Построение кривых обучения - learning_curve





Перекрестная проверка означает, что оценка снижается, поскольку при регрессии оптими: ошибки, а не точность.

▼ Построение кривой валидации - validation_curve

```
CV-CV, SCOTING-SCOTING, N JODS-1)
train scores mean = np.multiply(np.mean(train scores, axis=1),-1)
train scores std = np.std(train scores, axis=1)
test scores mean = np.multiply(np.mean(test scores, axis=1),-1)
test scores std = np.std(test scores, axis=1)
plt.title(title)
plt.xlabel(param name)
plt.ylabel(str(scoring))
plt.ylim(0.0, 1.1)
lw = 2
plt.plot(param range, train scores mean, label="Training score",
             color="darkorange", lw=lw)
plt.fill between(param range, train scores mean - train scores std,
                 train scores mean + train scores std, alpha=0.4,
                 color="darkorange", lw=lw)
plt.plot(param_range, test_scores_mean, label="Cross-validation score",
             color="navy", lw=lw)
plt.fill between(param range, test scores mean - test scores std,
                 test scores mean + test scores std, alpha=0.2,
                 color="navy", lw=lw)
plt.legend(loc="best")
return plt
```

 $\begin{tabular}{ll} \hline \begin{tabular}{ll} \hline \end{tabular} \end{ta$

