Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра «Автоматизированные системы обработки информации и управления»



Отчет по лабораторной работе № 6

«Ансамбли моделей машинного обучения»

По курсу

«Методы машинного обучения»

Выполнила: Шаххуд Ф.М. Студентка группы ИУ5И-22М

Москва, 2020

Цель лабораторной работы

Изучение ансамблей моделей машинного обучения.

```
from datetime import datetime
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean absolute error
from sklearn.metrics import median absolute error, r2 score
from sklearn.model selection import GridSearchCV
from sklearn.model selection import ShuffleSplit
from sklearn.model selection import train test split
from sklearn.preprocessing import StandardScaler
# Enable inline plots
%matplotlib inline
# Set plots formats to save high resolution PNG
from IPython.display import set matplotlib formats
set matplotlib formats("retina")
%matplotlib inline
```

Набор данных

Наш набор данных о лесных пожарах. У нас есть столбцы, которые описывают пожар, и мы предсказывает площадь пожара с помощью регрессии.

data=pd.read_csv('https://archive.ics.uci.edu/ml/machine-learning-databases/forestdata.head()

	x	Y	month	day	FFMC	DMC	DC	ISI	temp	RH	wind	rain	area
0	7	5	mar	fri	86.2	26.2	94.3	5.1	8.2	51	6.7	0.0	0.0
1	7	4	oct	tue	90.6	35.4	669.1	6.7	18.0	33	0.9	0.0	0.0
2	7	4	oct	sat	90.6	43.7	686.9	6.7	14.6	33	1.3	0.0	0.0
3	8	6	mar	fri	91.7	33.3	77.5	9.0	8.3	97	4.0	0.2	0.0
4	8	6	mar	sun	89.3	51.3	102.2	9.6	11.4	99	1.8	0.0	0.0
	1 2 3	0 71 72 73 8		 0 7 5 mar 1 7 4 oct 2 7 4 oct 3 8 6 mar 	 0 7 5 mar fri 1 7 4 oct tue 2 7 4 oct sat 3 8 6 mar fri 	0 7 5 mar fri 86.2 1 7 4 oct tue 90.6 2 7 4 oct sat 90.6 3 8 6 mar fri 91.7	0 7 5 mar fri 86.2 26.2 1 7 4 oct tue 90.6 35.4 2 7 4 oct sat 90.6 43.7 3 8 6 mar fri 91.7 33.3	0 7 5 mar fri 86.2 26.2 94.3 1 7 4 oct tue 90.6 35.4 669.1 2 7 4 oct sat 90.6 43.7 686.9 3 8 6 mar fri 91.7 33.3 77.5	0 7 5 mar fri 86.2 26.2 94.3 5.1 1 7 4 oct tue 90.6 35.4 669.1 6.7 2 7 4 oct sat 90.6 43.7 686.9 6.7 3 8 6 mar fri 91.7 33.3 77.5 9.0	0 7 5 mar fri 86.2 26.2 94.3 5.1 8.2 1 7 4 oct tue 90.6 35.4 669.1 6.7 18.0 2 7 4 oct sat 90.6 43.7 686.9 6.7 14.6 3 8 6 mar fri 91.7 33.3 77.5 9.0 8.3	0 7 5 mar fri 86.2 26.2 94.3 5.1 8.2 51 1 7 4 oct tue 90.6 35.4 669.1 6.7 18.0 33 2 7 4 oct sat 90.6 43.7 686.9 6.7 14.6 33 3 8 6 mar fri 91.7 33.3 77.5 9.0 8.3 97	0 7 5 mar fri 86.2 26.2 94.3 5.1 8.2 51 6.7 1 7 4 oct tue 90.6 35.4 669.1 6.7 18.0 33 0.9 2 7 4 oct sat 90.6 43.7 686.9 6.7 14.6 33 1.3 3 8 6 mar fri 91.7 33.3 77.5 9.0 8.3 97 4.0	1 7 4 oct tue 90.6 35.4 669.1 6.7 18.0 33 0.9 0.0 2 7 4 oct sat 90.6 43.7 686.9 6.7 14.6 33 1.3 0.0 3 8 6 mar fri 91.7 33.3 77.5 9.0 8.3 97 4.0 0.2

```
data.columns
```

```
data.dtypes
```

```
int64
   X
C→
                int64
    month object day object FFMC float64
    DMC
             float64
    ___oat64
___ float64
temp flor
RH
    DC
    wind
            float64
             float64
    rain
    area
             float64
    dtype: object
```

```
data.isnull().sum()
```

```
□→ X
           0
   month
          0
   day
           0
   FFMC
          0
   DMC
   DC
           0
   ISI
          0
   temp
   RH
   wind
           0
   rain
           0
            0
   area
   dtype: int64
```

наш набор данных не содержит пропущенных значений. поэтому не надо обрабатывать их. но мы должны иметь дело со столбцами объектов в нашем наборе данных.

▼ Кодирование категориальных признаков

```
ray(['fri', 'mon', 'sat', 'sun', 'thu', 'tue', 'wed'], dtype=object)
```

```
title_mapping = {"mon": 1, "tue": 2, "wed": 3,
                "thu": 4, "fri": 5, "sat": 6, "sun": 7 }
data['day'] = data['day'].map(title_mapping)
data.dtypes
              int64
Гэ
   X
             int64
    month
             int64
             int64
    day
          float64
    FFMC
    DMC
           float64
    DC
           float64
    TST
           float64
           float64
    temp
             int64
    RH
          float64
    wind
    rain
           float64
          float64
    area
    dtype: object
```

разделиние выборку на обучающую и тестовую.

- Выбор метрик для последующей оценки качества модел

мы будем использовать среднюю абсолютную ошибку и среднюю абсолютную ошибку

```
def test_model(model):
    return {'mean_absolute_error':mean_absolute_error(y_test, model.predict(X_test)),
        'median_absolute_error': median_absolute_error(y_test, model.predict(X_test))
```

Random Forest Regressor

Gradient Boosting Regressor

Подбор гиперпараметров для выбранных моделей

```
param_grid = {
    'max_depth' : [1, 2, 3, 4, 5],
    'max_samples' : [0.05, 0.1, 0.2, 0.5],
    'max_leaf_nodes':[10, 15],
    'n_estimators':np.array(range(1,100,10))
}
param_grid
```

```
{'max depth': [1, 2, 3, 4, 5],
     'max leaf nodes': [10, 15],
      'max samples': [0.05, 0.1, 0.2, 0.5],
                                11. 21. 31. 41. 51. 61. 71. 81. 91113
      'n estimators': arrav([ 1.
gs = GridSearchCV(RandomForestRegressor(), param grid,
                  cv=ShuffleSplit(n splits=10), scoring="neg mean squared error",
                    return train score=True, n jobs=-1)
gs.fit(X train, y train)
gs.best_estimator_
□→ RandomForestRegressor(bootstrap=True, ccp alpha=0.0, criterion='mse',
                          max depth=1, max features='auto', max leaf nodes=10,
                          max samples=0.2, min impurity decrease=0.0,
                          min impurity split=None, min samples leaf=1,
                          min_samples_split=2, min_weight_fraction_leaf=0.0,
                          n_estimators=31, n_jobs=None, oob_score=False,
                          random state=None, verbose=0, warm start=False)
gs.best_params_
['max_depth': 1, 'max_leaf_nodes': 10, 'max_samples': 0.2, 'n_estimators': 31]
reg = gs.best estimator
reg.fit(X train, y train)
new_metrics_RF=test_model(reg)
new metrics RF
[ 'mean_absolute_error': 20.133763760414713,
      'median absolute error': 7.689291702435838}
param grid = {
    'max depth': [1, 2, 3, 4, 5],
    'max_leaf_nodes':[10, 15],
    'n estimators':np.array(range(1,100,10))
}
gbr = GridSearchCV(GradientBoostingRegressor(), param_grid,
                            cv=ShuffleSplit(n_splits=10), scoring="neg_mean_squared"
                              return_train_score=True, n_jobs=-1)
gbr.fit(X_train, y_train)
gbr.best estimator
GradientBoostingRegressor(alpha=0.9, ccp_alpha=0.0, criterion='friedman_mse',
                               init=None, learning_rate=0.1, loss='ls', max_depth=3
                              max_features=None, max_leaf_nodes=15,
                              min impurity decrease=0.0, min impurity split=None,
                              min_samples_leaf=1, min_samples_split=2,
                              min_weight_fraction_leaf=0.0, n_estimators=71,
                              n_iter_no_change=None, presort='deprecated',
                              random_state=None, subsample=1.0, tol=0.0001,
                              validation_fraction=0.1, verbose=0, warm_start=False
```

```
reg = gbr.best_estimator_
reg.fit(X_train, y_train)
rev.metrics_CRP=test_model(res)
```

```
new_metrics_GBR

['mean_absolute_error': 22.664977187130713,
    'median_absolute_error': 6.494514329418848}
```

Сравниние качество полученных моделей